SafeNet Modeli: Eğitim Öncesi Tasarım

Sysplex Squad · IBM Z Datathon 2026 · 17 Ekim 2026 · Takım içi gözden geçirme belgesi

> **Bu belge neden var?** Modeli eğitmeden önce herkesin tasarımı görüp itiraz edebilmesi için. Değiştirmek istediğiniz bir şey varsa **Bölüm 11'deki karar listesindeki** numarayla yazın. 17 Ekim'de verilen kararlar listede **yeşil** işaretli.

1. Özet

SafeNet bir uygulama ya da platform **değil**; uygulamaların ve platformların bağlandığı bir **güvenlik API servisi**. Platform, bir mesajı alıcıya ulaştırmadan önce SafeNet'e sorar; SafeNet **alıcının ne göreceğine** karar verir: olduğu gibi teslim et, küfürleri sansürleyerek teslim et ya da engelle. Cevap milisaniyeler içinde, IBM LinuxONE sunucusundan döner.

- **Kapsam:** şimdilik sadece **birebir mesajlaşma**. Grup ve canlı yayın sohbetleri sonraki aşamaya kaldı.
- **İki küçük model** eğitilecek: Model 1 "zararlı mı?", Model 2 "neye yönelik?". İkisi de **TF-IDF + lojistik regresyon** (scikit-learn): hızlı, ekran kartı istemez, kararını kelime kelime açıklayabilir. LinuxONE'da büyük dil modelleri (torch) zaten kurulamıyor.
- Modellerin etrafında **bizim yazdığımız kurallar** var: gizli küfür çözme, sansür, kimlik analizi, gizli puanlar. Puanlar **platform, topluluk ve kullanıcı** seviyesinde ayrı ayrı tutulur ve **zamanla değil, düzgün davranışla** düşer. **Mesaj metni saklanmaz.** Bütün sayılar tek bir ayar dosyasında (ayarlar.toml).
- **Alıcıyı korur:** her mesaj için alıcıya neyin teslim edileceğine karar verir. Çocukları korumak için küfür, arkadaştan da gelse puanlanır.
- **Platformları biz yapılandırırız:** her platform için hazır bir profil seçilir ve gerekirse ona özel değerler eklenir (ayarlar.toml). Platform API'ye kendi anahtarıyla bağlanır, istekte ayar göndermez.
- **Veri hazır:** 187.997 mesaj, bunların 41.824'i zararlı. Eğitim 150.409 / test 37.588. Eğitim sunucuda birkaç dakika sürecek.

2. API nasıl çalışır?

Platform her birebir mesaj için SafeNet'e bir istek gönderir. SafeNet mesajı inceler ve alıcının göreceği hali, kararın nedenini ve puanları geri döner. Alan adları taslaktır; API yazılırken netleşecek.

İstek (platform → SafeNet)

```
POST /kontrol
API-Anahtari: <platformun gizli anahtarı>
{
  "gonderen_id": "u_4821",
  "alici_id": "u_1093",
  "topluluk_id": "t_77",
  "metin": "Great match yesterday Mark.
            But if you show up on Friday
            I'll f*cking break your legs."
}
```

Cevap (SafeNet → platform)

```
{
  "karar": "engelle",
  "alicinin_gorecegi": null,
  "neden": "tehdit",
  "en_kotu_cumle": "but if you show
     up on friday i'll f****** break
     your legs.",
  "zararlilik": 0.96,
  "kelimesiz_puan": 0.93,
  "kategori": "tehdit",
  "etkili_kelimeler": ["break your legs",
                       "i'll"],
  "gizli_kufurler": ["f*cking -> fucking"],
  "gonderen": {"seviye": "uyarilmis",
               "puan_degisimi": 48},
  "onerilen_eylem": "gonderene_uyari"
}
```

API'nin verebileceği kararlar

Karar	Alıcı ne görür	Ne zaman
teslim_et	Mesajın kendisi	Zararsız, içinde küfür yok
sansurlu_teslim_et	Küfürleri yıldızlanmış mesaj (f***)	İçinde küfür var ya da mesaj sarı bölgede
beklet	Hiçbir şey (moderatör onayına kadar)	Platform ayarı sarı mesajlar için "beklet" diyorsa; alıntılanan tehditler
engelle	Hiçbir şey; platform isterse "bir mesaj engellendi" yazar	Kırmızı mesaj; gönderen kısıtlı; ya da alıcı bu gönderenden artık mesaj almıyor (ilişki eşiği)

SafeNet bir uygulama değil, güvenlik API'sidir: sadece alıcıya neyin teslim edileceğine karar verir. Hesap kapatma, gönderene uyarı göstermek gibi işler platformundur; API bunları cevaptaki onerilen_eylem alanıyla bildirir. "beklet" kararında mesajı platform tutar, API değil. Platform istekte ayar ya da profil göndermez: API onu anahtarından tanır ve SafeNet ekibinin yaptığı yapılandırmayı kullanır (Bölüm 7).

API neyi tutar? Üç seviye + ilişki

Her istekte platform_id, topluluk_id (yoksa "genel") ve kullanıcı kimlikleri gelir. API bunları **ayrı ayrı** tutar ve puanlar:

Seviye	Ne tutulur	Ne işe yarar
Platform	Mesaj sayısı, zararlı oranı, kategori dağılımı, kısıtlı kullanıcı sayısı	Platformun genel durumu; yönetim paneli
Topluluk (sınıf, sunucu, klan...)	Aynı sayaçlar, topluluk bazında	"Topluluk sağlığı": hangi sınıf ya da sunucu kötüleşiyor, platforma bildirilir
Kullanıcı (topluluk içinde)	Gizli puan, son 10 mesajın temiz olup olmadığı, kısıtlama durumu ve sayısı	Tekrar eden davranış: 40 puanda uyarı önerisi, 70 puanda kısıtlama (kısıtlama süresince mesajları kimseye teslim edilmez)
İlişki (A → B, platform genelinde)	A'nın sadece B'ye yazdıklarından gelen puan	Birebir zorbalık genelde tek kişiye yönelir: puan 40'a ulaşınca **A'dan gelen mesajlar B'ye teslim edilmez**. A'dan başkalarına giden mesajlar bundan etkilenmez.

Mesaj metni saklanmaz (karar). API sadece puanları, sayaçları ve son 10 mesajın temiz olup olmadığını tutar. Kaba hesap: metin saklansaydı 1 milyon kullanıcı × günde 50 mesaj × ~100 bayt = **günde ~5 GB, ayda ~150 GB** birikirdi. Saklanmadığında kullanıcı başına ~200 bayt yeter: **1 milyon kullanıcı ≈ 200 MB** ve bu, mesaj sayısı arttıkça büyümez. Ayrıca çocukların mesajları hiçbir yerde birikmediği için gizlilik riski de yoktur. İlişki kaydı sadece puanı 0'dan büyükse tutulur.

3. Bir mesajın yolculuğu

Her mesaj aşağıdaki 9 adımdan geçer. Mavi kutuları model yapar, beyaz kutular bizim kurallarımızdır.



Bölüm 2'deki örnek mesaj adım adım (sayılar örnektir):

Adım	Sonuç
2. Temizlik	"... i'll fucking break your legs." · gizli küfür: f*cking → fucking · birebir olduğu için hedefli
3. Cümleler	2 cümle
4. Model 1	1. cümle %3 · 2. cümle %96
5. Kelimesiz puan	"fucking" çıkarılınca 2. cümle hâlâ %93 → kötülük kelimede değil, cümlenin kendisinde
6. Model 2	tehdit (%88)
7. Kimlik analizi	kimlik kelimesi yok → kimlik puanı 0
8. Karar	**engelle**: kategori tehdit ve puan ≥ 0,60 → **mesajın tamamı** engellenir (1. cümle masum olsa bile)
8. Gönderen puanı	+40 (tehdit) + 5 (fucking) + 3 (gizlemeye çalıştı) = +48 → uyarı eşiği 40 geçildi, seviye "uyarılmış"

4. Veri

Dört İngilizce veri setinden 217.210 mesajla başladık; temizlik ve elle kontroller sonrası **187.997** mesaj kaldı. Model sadece bu tabloyu görecek.

Kaynak	Mesaj	Zararsız	Zararlı
Cyberbullying tweetleri (ırk/din/cinsiyet etiketli)	30.912	7.599	23.313
Twitter cinsiyetçilik/ırkçılık	7.424	6.241	1.183
Wikipedia tartışma yorumları	141.148	126.609	14.539
Kaggle hakaret yorumları	8.513	5.724	2.789
Toplam	**187.997**	**146.173**	**41.824**

Ayrıca eğitimde **kullanılmayan** üç test seti var: YouTube son sınavı (3.459 mesaj, hiç görülmemiş bir platform), belirsiz set (70 mesaj, gri bölge) ve 124 masum cümle testi ("I fed the duck", "I was bullied at school" gibi).

Verinin hazırlanmasında alınan kararlar

- **"Yaş" grubu çıkarıldı.** Mesajların %98'i "bully" kelimesini içeriyordu; çoğu insanların okulda yaşadığı zorbalığı anlattığı tweetlerdi. Zararlı sayılsaydı sistem kurbanı susturacaktı.
- **Temizlik:** her şey küçük harfe çevrilir, linkler <url> olur, @isimler ve emojiler silinir, Wikipedia işaretleri temizlenir, uzatılmış harfler kısalır.
- **Gizli küfürler çözülür:** f*ck, sh1t, a$$, f u c k, Kiril harfli "ass", fck, stfu, kys → düz hali. 1.471 mesajda gizlenmiş küfür bulundu.
- **Atılanlar:** 1.000 karakterden uzun mesajlar (13.104, çoğu uzun Wikipedia yazısı), 3 harften kısa mesajlar, Wikipedia sistem satırları, birebir tekrarlar.
- **Elle kontrol:** şüpheli 370 etiket ve 215 çelişkili grup tek tek okundu. Toplam 785 karar satırı: 322 zararlı, 297 zararsız, 166 belirsiz (belirsizler eğitime girmez, belirsiz test setine gider).
- **Neredeyse aynı mesajlar gruplandı:** retweetler, yazım hatalı kopyalar ve şablon mesajlar 1.427 grupta toplandı. Her gruptan en fazla 3 mesaj tutuldu, fazla kopyalar atıldı.
- **Eğitim/test bölmesi:** her kaynak ve etiketten %80/%20, rastgele ama her seferinde aynı (random_state=42). Benzer mesaj grupları bölünmez. Kontrol: eğitim ile test arasında **0 ortak grup, 0 aynı mesaj**.

Zararlı mesajların kategorileri

Wikipedia ve Kaggle mesajlarında sadece "zararlı" yazıyordu. Bunlara kelime kurallarıyla kategori verdik (zayıf etiketleme). Kuralların isabeti kaba bir göz kontrolüyle: tehdit ve ırk ~%80, diğerleri ~%65.

Kategori	Toplam	Veri setinin etiketi	Bizim kuralımız	Elle düzeltme
Genel hakaret	13.128	0	12.998	130
Cinsiyet ve cinsel yönelim	10.092	8.389	1.673	30
Din	8.770	8.267	500	3
Irk / etnik köken	8.585	7.796	740	49
Cinsel içerik	768	0	768	0
Tehdit	481	0	474	7

Yaş kategorisi yok: güvenilir veri bulunamadı. Tehdit ve cinsel içerik örnekleri az olduğu için bu iki kategori diğerlerinden zayıf kalabilir.

5. İki model ve eğitim planı

Aşağıdaki seçimler henüz uygulanmadı; eğitimden önce itiraz edilebilir (Bölüm 11).

	Model 1: Zararlı mı?	Model 2: Neye yönelik?
Ne öğrenir	Mesajın zararlı olma ihtimali (%0–100)	6 kategorinin her birinin ihtimali
Hangi veriyle	Bütün eğitim verisi (150.409 mesaj)	Sadece zararlı mesajlar
Metni nasıl okur	Kelimeler ve 2'li kelime grupları + 2–5 harflik parçalar (TF-IDF). Harf parçaları yanlış yazılmış ve gizlenmiş kelimeleri de yakalar.	Aynı
Karar veren kısım	Lojistik regresyon	Çok sınıflı lojistik regresyon
Dengesizlik	Zararlılar %22; az olan sınıfa daha çok önem verilir (class_weight=balanced)	Aynı (tehdit 481, cinsel 768 örnek)
Güven ağırlığı	–	Kuralla etiketlenen örnekler yarım ağırlık (0,5), insan etiketliler tam (1,0)
Ayar seçimi	Eğitim verisi 5 parçaya bölünüp sırayla denenir (çapraz doğrulama), benzer gruplar bölünmeden. Test seti sadece en sonda bir kez açılır.	Aynı
Çıktı	Puan + puana en çok etki eden kelimeler	Kategori + ihtimaller
Başarısı nasıl ölçülür	Test seti, YouTube, masum cümleler, belirsiz set	Sadece insan etiketli test örnekleri (kendi kuralımızı ezberlemesin)

Eğitim nerede ve nasıl yapılacak?

- Eğitim **LinuxONE sunucusunda** yapılacak. Sunucunun işlemcisi sayıları ters sırada saklıyor (big-endian); başka bilgisayarda eğitilip taşınan model dosyası bozuk çalışabilir.
- Gerekli kütüphaneler sunucuda kurulu (numpy, scikit-learn, pandas, FastAPI). 3 işlemciyle birkaç dakika sürmesi bekleniyor.
- Model dosyaları küçük olacak (birkaç MB). Mesaj başına süre hedefi birkaç milisaniye.

6. Modelin etrafındaki kurallar

Bunlar öğrenilmez; bizim yazdığımız kurallardır ve sayıları ayarlar.toml dosyasından değiştirilebilir.

Özellik	Ne yapar	Durum
Gizli küfür çözme	f*ck, sh1t, a$$, f u c k, fck, stfu, kys → düz hali. 30 gizleme yöntemi ve 30 masum ifadeyle test edildi ("class", "5-0", "c++" bozulmuyor).	Hazır
Sansür	Küfür listesindeki (125 kelime ve yazım çeşidi) **her kelime her zaman** alıcıya yıldızlanmış gider. Her kelimenin 1–10 arası bir puanı var (damn 1, fuck 6, cunt 8, ırkçı hakaret 9, kys 10); puan sadece gönderen puanına eklenir.	Liste hazır
Cümle bazlı karar	Mesaj cümlelere bölünür; en kötü cümle bütün mesajın kaderini belirler.	API'de
Kelimesiz puan	Cümle, içindeki küfürler çıkarılarak tekrar puanlanır. "fuck, I missed the bus" (sadece küfür) ile "fuck you, nobody likes you" (kötü niyet) böyle ayrılır.	API'de
Olası yazım hatası	124 karıştırılabilir kelime (duck/fuck, clock/cock...) ve bağlam ipuçları. "I fed the fuck at the lake" → puan eklenmez, kelime yine sansürlenir, cevapta "olası düzeltme: duck" döner.	Liste hazır
Kimlik analizi	Kimlikten bahsetme (0 puan) / bir grubu genelleme / alıcıya kimliği üzerinden saldırı ayrılır. "I'm a proud Muslim" 0, "you dirty muslim" hedefli saldırı.	Hazır
Alıcı koruması (ilişki)	A'nın B'ye yazdıklarından gelen puan 40'a ulaşınca A'dan gelen mesajlar B'ye teslim edilmez; A'dan başkalarına giden mesajlar etkilenmez.	Ayarlar hazır, kod API'de
Gönderen puanı	Kimseye gösterilmez; küfür ve kötü mesajlarla artar, **zamanla değil düzgün mesajlarla** azalır; eşikte uyarı önerisi, sonra kısıtlama (mesajları teslim edilmez).	Ayarlar hazır, kod API'de

Mesaj kararı (varsayılan değerler)

Sonuç	Ne zaman	API kararı
KIRMIZI	Bir cümlenin kelimesiz puanı ≥ 0,85; veya tehdit ve puan ≥ 0,60; veya ırk/din/cinsiyet ve kelimesiz puan ≥ 0,75; veya kelimelerin %30'undan fazlası küfür	engelle
SARI	Zararlılık puanı ≥ 0,50 (kırmızı değilse)	sansurlu_teslim_et (profil izin verirse beklet)
YEŞİL	Diğer her şey	teslim_et (küfür varsa sansurlu_teslim_et)

Alıntı koruması: tırnak içindeki ya da "he told me ..." diye aktarılan tehditler engellenmez, beklet kararıyla moderatöre gider (zorbalığa uğrayan kişi susturulmasın diye).

7. Ayarlar: profiller ve platform yapılandırması

Platformları **SafeNet ekibi** yapılandırır. Her platform ayarlar.toml'da bir blokla tanımlanır: aşağıdaki hazır profillerden biri ve varsa o platforma özel değerler. Platform istekte ayar göndermez; API anahtarından tanınır. Yeni platform eklemek için kod değişmez, sadece yeni bir blok yazılır.

Hazır profiller

Ayar	Sosyal medya	Eğitim / çocuk	Oyun	Kurumsal
Sarı eşiği	0,50	0,40	0,60	0,45
Çok kötü (kelimesiz) eşiği	0,85	0,75	0,90	0,80
Tehdit eşiği	0,60	0,50	0,70	0,55
Nefret eşiği	0,75	0,65	0,75	0,75
Sarı mesaja ne yapılır	sansürlü teslim + uyarı önerisi	beklet	sansürlü teslim	beklet
Oyun dili serbest (kill, die...)	hayır	hayır	evet	hayır
Uyarı eşiği (puan)	40	30	50	35
Kısıtlama eşiği (puan)	70	50	90	60
İlişki: A'dan B'ye teslim durur (puan)	40	30	50	40
İyileşme: son 10 mesajda en az kaç temiz	7	8	7	7
İyileşme: temiz mesaj başına düşüş	%10	%5	%15	%10
Kimlik: genelleme / hedefli	20 / 30	30 / 40	20 / 30	20 / 40

Tanımlı platformlar (demo için örnek)

platform_id	Platform	Profil	Bu platforma özel değerler
`demo_okul`	Demo: okul mesajlaşma uygulaması	egitim	yok
`demo_oyun`	Demo: çevrim içi oyun	oyun	gizli_puan.susturma_esigi = 80
`demo_sosyal`	Demo: sosyal medya uygulaması	sosyal_medya	yok

Örnek: demo_oyun, oyun profilini kullanıyor ama kısıtlama eşiğini 90 yerine 80 istedi; bu tek satırla yapılıyor. API anahtarları ayarlar.toml'da değil, ayrı ve gizli tutulur.

Gönderen puanı nasıl artar? (varsayılan)

Olay	Puan
Sansürlenen küfür	kelimenin puanı (1–10) × 1,0; tek mesajdan en fazla 15
Küfrü gizlemeye çalışmak (f*ck, sh1t)	kelime başına +3
Sarı mesaj / engellenen mesaj	+10 / +25
Engellenen tehdit / spam	+40 / +20
Kimlik: zararlı bahsetme / genelleme / hedefli saldırı	+10 / +20 / +30, birebirde ×1,5 (sadece model mesajı zararlı bulduysa)
Uyarı / kısıtlama	40 puanda uyarı önerisi; 70 puanda kısıtlama: 5 → 60 → 1440 dakika; sonra puan 35'e iner
Düzgün davranış (puan düşer)	son 10 mesajın en az 7'si temizse her yeni temiz mesajda puan %10 azalır · zamanla düşme yok (Bölüm 8)
İlişki puanı (A → B)	aynı olaylar, sadece A'nın B'ye mesajları için; 40 puanda A'dan gelen mesajlar B'ye teslim edilmez; A'nın B'ye düzgün mesajlarıyla aynı kuralla iyileşir
Arkadaşlar arası küfür	**indirim yok**: çocukları korumak için küfür kimden gelirse gelsin puanlanır

Birebirde her mesaj alıcıya yazılmış sayılır (hedefli). Grup ve canlı yayın ayarları dosyada duruyor ama bu aşamada kullanılmayacak. Bütün sayılar başlangıç tahminidir; eğitimden sonra ölçülerek ayarlanacak.

8. Gönderen puanı nasıl iyileşir?

> **Karar verildi:** puan zamanla **düşmez**. Gönderen düzgün yazdıkça iyileşir: son 10 mesajının en az 7'si temizse, her yeni temiz mesajda puanı %10 azalır. "Temiz" mesaj = yeşil ve küfürsüz.

Neden? Zamanla düşen puan, günlere yayılan zorbalığı kaçırıyordu ve "bir süre susup geri dönmek" cezayı siliyordu. Burada ceza ancak düzgün davranışla silinir. Aşağıdaki sayılar varsayılan ayarlarla hesaplandı:

Gönderen	Ne olur
Bir kez 2 küfürlü mesaj atıp sonra düzelen (tövbe eden)	Puan 12 → 10 temiz mesaj sonra 8,7 → 20 temiz mesaj sonra 3,1: **affedilir**
Her 3 mesajından biri ağır hakaret olan (engellenen mesaj +25, "fuck" +6)	9. mesajında puan 70'i geçer: **kısıtlanır**. Aradaki temiz mesajlar onu kurtarmaz.
Çoğunlukla düzgün, her 10 mesajda bir "shit" yazan	50 mesaj sonra puan 6,5: **sorun yok**
50 puandayken 3 gün susup geri dönen	Puan 50'de kalır; ilk engellenen mesajında 75 olur: **kısıtlanır**. Beklemek işe yaramaz.
Hiç yazmayan	Puanı değişmez; düşmesi için düzgün mesaj yazması gerekir.

Kısıtlamanın **süresi** (5 → 60 → 1440 dakika) zamana bağlıdır, puan değildir. Eğitim profilinde iyileşme daha zor (10 mesajın en az 8'i temiz, %5), oyun profilinde daha kolay (%15).

9. Ölçüm planı ve önerilen hedefler

Hedefler **öneridir**; takım onaylasın ya da değiştirsin. Eşikler bu ölçümlere göre seçilecek, tahminle değil.

Ölçüm	Hangi veriyle	Önerilen hedef
Zararlı mesajların yakalanma oranı	Test seti	≥ %85
Masum mesajlarda yanlış alarm	Test seti	≤ %5
Kaynaklar arası fark (kaynak tuzağı)	Test seti, kaynak kaynak	Raporlanır; büyük fark varsa veri dengelenir
Hiç görülmemiş platform	YouTube (3.459 mesaj)	Raporlanır
Masum cümleler (duck, Muslim, bullied...)	124 cümle	Hiçbiri engellenmemeli
Gri bölge	Belirsiz set (70 mesaj)	Çoğu sarı bölgede (orta puan)
Kategori doğruluğu	Test, sadece insan etiketli	≥ %75
API hızı	LinuxONE	Mesaj başına < 10 ms
Gönderen puanı sistemi	Birebir simülasyonu (80 kullanıcı)	Kısıtlanması gerekenlerin ≥ %90'ı kısıtlanır; normal, kurban ve tövbe edenlerin ≤ %5'i
Alıcı koruması (ilişki)	Birebir zorbalık sohbetleri	Her zorbalık sohbetinde kurban, zorbadan gelen mesajları almamaya başlar

Birebir simülasyonu (test ve demo için hazır)

Gerçek mesajlaşma verisi olmadığından, modelin hiç görmediği test mesajlarından 40 sahte birebir sohbet (1.132 mesaj) kuruldu. Kullanıcıların davranışı bilindiği için gönderen puanı sistemi ölçülebilir. Eğitimde kullanılmaz.

Senaryo	Sohbet
normal	16
zorbalık	6
şakalaşma	4
tırmanan	4
tövbe	4
kavga	3
gizlemeci	3

Kullanıcı tipleri: kurban 6, normal 43, tövbe eden 4 (kısıtlanmamalı) · gizlemeci 3, şakacı 8, tırmanan 4, trol 6, zorba 6 (kısıtlanmalı).

10. Sınırlar (jüri sorarsa dürüst cevaplar)

- **Sadece İngilizce.** Türkçe için Türkçe etiketli veriyle yeniden eğitim gerekir.
- **Şimdilik sadece birebir mesajlaşma;** grup ve canlı yayın sonraki aşamada.
- **API sadece platformun gönderdiği mesajları görür.** Hesap kapatma, ban, arayüz gibi işler platformundur; API önerir.
- **Kullanıcı puanı topluluk başına tutulur:** başka bir topluluğa geçen kullanıcı orada sıfırdan başlar. Ama ilişki puanı platform genelinde olduğu için kurban, zorbadan gelen mesajları hangi toplulukta olursa olsun almamaya devam eder.
- **İroni ve derin anlam:** basit model kelimelere ve harf parçalarına bakar; alaycı mesajları kaçırabilir.
- **Sohbet geçmişini görmez:** her mesajı tek başına değerlendirir. Gönderenin geçmişi gönderen puanına yansır.
- **Emojileri görmez** (takım kararıyla siliniyor). **Yaş kategorisi yok;** tehdit ve cinsel içerik örnekleri az.
- **Kategorilerin bir kısmı kurallarla etiketlendi** (zayıf etiketleme); gerçek başarı insan etiketli örneklerle ölçülür.
- **Kendi kendine öğrenmez:** yeni argo için listeyi güncellemek ya da yeniden eğitmek gerekir.

11. Karar listesi: eğitimden önce onaylayın ya da değiştirin

Bir maddeye itirazınız varsa numarasıyla yazın. Eğitim ve API bu listeye göre yapılacak.

#	Karar	Şu anki seçim	Alternatif	Nerede
1	Kapsam	Güvenlik API servisi (uygulama değil); alıcıya neyin teslim edileceğine karar verir; şimdilik sadece birebir · **karar verildi**	Grup / canlı yayın (sonra)	–
2	Model türü	TF-IDF + lojistik regresyon	Büyük model (LinuxONE'da kurulamıyor)	eğitim kodu
3	Metni okuma	Kelime 1–2'li + harf 2–5'li parçalar	Sadece kelimeler	eğitim kodu
4	Dengesizlik	Az olan sınıfa daha çok ağırlık	Zararsızları azaltmak	eğitim kodu
5	Kural etiketlerinin ağırlığı	0,5	1,0 ya da hiç kullanmamak	eğitim kodu
6	Kategoriler	6 kategori, yaş yok	Yaş eklemek (veri gerekir)	`kategoriler.py`
7	Emojiler / kısa mesajlar	Emoji siliniyor; 3 harften kısa mesajlar atılıyor	Tutmak	`temizlik.py`
8	Uzun mesajlar	1.000 karakterden uzun olanlar atılıyor	Sınırı değiştirmek	`EN_UZUN`
9	Benzer mesajlar	Parçaların %80'i ortaksa benzer; grup başına en fazla 3	%70–90; 1 ya da sınırsız	`benzerlik.py`
10	Belirsiz mesajlar	Eğitime girmez, ayrı testte	Eğitime %50 etiketle girmek	`etiket_duzeltmeleri.csv`
11	Arkadaşlar arası n-kelimesi	Düşmanlık yoksa zararsız etiket, ama kelime her zaman sansürlenir	Hep zararlı etiketlemek	`etiket_duzeltmeleri.csv`
12	Küfür puanları	Kelime başına 1–10	Farklı puanlar	`kufur_listesi.csv`
13	Eşikler	Bölüm 6–7'deki değerler	Farklı değerler	`ayarlar.toml`
14	Kimlik puanları	10 / 20 / 30, birebirde ×1,5	Farklı değerler	`ayarlar.toml`
15	Puanın iyileşmesi	Zamanla düşmez; son 10 mesajın en az 7'si temizse her temiz mesajda %10 · **karar verildi**	Kademeli: 7/10 → %5, 9/10 → %15	`ayarlar.toml`
16	Puanlama seviyeleri	Platform, topluluk ve kullanıcı ayrı ayrı tutulur ve puanlanır; kullanıcı puanı topluluk içinde · **karar verildi**	Kullanıcı için tek platform puanı	API
17	Alıcı koruması (ilişki)	A'nın B'ye yazdıklarından gelen puan 40'a ulaşınca A'dan gelen mesajlar B'ye teslim edilmez · **karar verildi**	Farklı eşik	`ayarlar.toml`
18	Arkadaşlar arası küfür	İndirim yok: çocukları korumak için küfür kimden gelirse gelsin puanlanır · **karar verildi**	Karşılıklı küfürde indirim	–
19	Mesaj metni	Saklanmaz; sadece puan, sayaç ve son 10 mesajın temiz bilgisi (kullanıcı başına ~200 bayt) · **karar verildi**	Engellenen mesajları kısa süre saklamak	API
20	Olası yazım hatası (duck/fuck)	Puan yok, kelime sansürlenir, cevapta öneri döner	Otomatik düzeltmek	API
21	Platform yapılandırması	SafeNet ekibi yapar: her platform = hazır profil + kendine özel değerler; platform API anahtarıyla tanınır · **karar verildi**	Platform her istekte profil seçer	`ayarlar.toml`
22	Başarı hedefleri	Bölüm 9'daki öneriler	Farklı hedefler	–

12. Dosya haritası (SafeNet klasörü)

Dosya	Ne yapar
`veri_hazirla.py`	Veri setlerini birleştirir, temizler, kararları uygular, böler (yaklaşık 1 dakika)
`temizlik.py`	Metin temizliği, gizli küfür çözme, "hedefli mi?" kontrolü (API de aynısını kullanacak)
`benzerlik.py`, `kategoriler.py`	Benzer mesajları bulur · türü bilinmeyen zararlı mesajlara kategori kuralları
`kimlik.py`	Kimlikten bahsetme / genelleme / hedefli saldırı ayrımı
`ayarlar.toml`, `ayarlar.py`	Hazır profiller, platform yapılandırmaları ve bütün eşikler; python ayarlar.py profilleri ve tanımlı platformları gösterir
`kufur_listesi.csv`	125 küfür ve yazım çeşidi, puanlarıyla (1–10)
`karistirilabilir_kelimeler.csv`	124 karıştırılabilir kelime, bağlam ipuçları, masum test cümleleri
`etiket_duzeltmeleri.csv`	Elle verilen 785 karar (zararlı / zararsız / belirsiz)
`sohbet_simulasyonu.py`	Sohbet simülasyonlarını üretir (şimdilik birebir kullanılacak)
`api.py` (yazılacak)	Mesaj kontrol API'si (FastAPI): istek alır, karar ve alıcının göreceği metni döner
`veri/`	birlesik_veri.csv, youtube_test.csv, belirsiz_test.csv, sohbetler/ (GitHub'a sadece seçilen CSV'ler gider)